DSL 的误区

DSL 时不时地会成为一个话题, 所以今天想专门说一下。

DSL 也就是 Domain Specific Language 的简称,是指为特定领域(domain)设计的专用语言。举个例子,Linux 系统下有很多配置文件,每个配置文件格式都不大一样,它们可以被看成是多种 DSL。IP Tables 的规则是一种 DSL,FVWM 窗口管理器的配置文件是一种 DSL,VIM 和 Emacs 的配置文件,当然也是 DSL。Makefile 是 DSL。CSS 是 DSL。JSON 是 DSL。SQL 也可以被看成是数据库领域的 DSL。也有很多人在自己的工作中创造 DSL,用它们来解决一些实际问题。

由于自己的原则,我个人从来没有设计过 DSL,但我用过别人设计的 DSL,并且对此深有感受。我觉得人们对于 DSL 有挺多的误解,所以我今天想分享一下自己对 DSL 的看法和亲身经历。

DSL 与库代码 (Library)

开门见山说说对 DSL 的看法吧。我觉得大部分 DSL 都是不应该存在的,我们应该尽量避免创造 DSL。这一论点不但适用于只有少量用户的产品内部 DSL,也适用于像 SQL 这样具有大量从业者的 DSL。

DSL 这名字本身就是一种误导,它让人误以为不同"领域"(domain)的人就该用不同的语言,而其实不是那样的。这不过是在制造领域壁垒,为引入不必要的 DSL 找借口。绝大部分所谓不同"领域",它们对语言的基本需求都是一样的。很多时候人们误以为需要新的 DSL,是因为他们没有分清"库代码"(library)和"新语言"(language)的差别。

不同领域需要的,绝大部分时候只是针对该领域写出的"库代码",而不是完全不同的"新语言"。分析大部分所谓 DSL,你会发现它们不过提取了通用程序语言里的一部分,比如结构定义,算术表达式,逻辑表达式,条件语 句,等等。极少有 DSL 是不能用通用的程序语言构造表示的。绝大部分时候你都可以用一种通用的语言,写出满足领域需求的库代码,然后领域里的人就可以调用库函数来完成他们的任务。

绝大部分 DSL 的存在,都是因为设计它的人没有理解问题的本质,没有意识到这问题并不需要通过设计新的语言来解决。很多人设计 DSL,是因为看到同类产品里面有 DSL,所以就抄袭照搬。或者因为听说 DSL 很酷,设计出 DSL 会显得自己很厉害,很有价值。同时,设计 DSL 还可以让同事和公司对自己产生依赖性。因为有人用我的 DSL,所以公司需要我,离不开我,那么 job security 就有所保证;)

然而如果你仔细分析手头的问题,就会发现它们绝大部分都可以用库代码,利用已有的语言来解决。就算类似的产品里面实现了 DSL, 你会发现它们绝大部分也可以用库代码来代替。在自己的工作中,我一般都首先考虑写库代码来解决问题,实在解决不了才会考虑创造 DSL。

因为遵循这一原则,加上对问题透彻的理解,我发现自己几乎每次都能用库代码解决问题,所以我从来没有在自己的职业生涯中创造过 DSL。

"新语言问题" (The New Language Problem)

现在我来讲一下,盲目创造 DSL 带来的问题。很多人不明白 DSL 跟库代码的区别,拿到一个问题也不想清楚,就一意孤行开始设计 DSL,后来却发现 DSL 带来了严重的问题。由于 DSL 是一种新的语言,而不只是用已有语言写出来新函数,所以 DSL 必须经过一个学习和理解的过程,才能被其他人使用。

举个例子。如果你看到 foo(x, y + z) 这样的库代码,很显然这是一个函数调用,所以你知道它会先计算 y+z,得到结果之后,把它传递给 foo 函数作为参数,最后得到 foo 函数算出来的结果。注意到了吗,你并不需要学习新的语言。虽然你不知道 foo 函数的定义,然而你很清楚函数调用会做什么:把参数算好放进去,返回一个结果。也就是说,你对函数调用已经有一个"心理模型"。

可是一个 DSL 就很不一样,对于一个新的 DSL 构造,你也许没有任何心理模型存在。同样看到 foo(x, y + z),它的含义也许根本不是一个函数调用。也许 foo 在这个 DSL 里就表示 foreach 循环语句,那么 foo(x, y + z) 表示类似 Java 的 foreach(x : y + z),其中 y 和 z 都是链表,+ 号表示连接两个链表。

这样一来,为了理解 foo(x, y + z) 是什么意义,你不能直接通过已有的,关于函数的心理模型,而必须阅读 DSL 设计者给你的文档,重新学习。如果 DSL 设计者是有素养的语言专家,那也许还好说。然而我发现绝大部分 DSL 设计者,都没有受到过专业的训练,所以他们设计出来的语言,从一开始就存在各种让人头痛的问题。

有些 DSL 表达力太弱,所以很多时候用户发现没法表达自己的意思。每当需要用这 DSL 写代码,他们就得去请教这个语言的设计者。很多时候你必须往这个 DSL 添加新的特性,才能解决自己的问题。到后来,你就发现有人设计了个 DSL,到头来他自己是唯一会用这 DSL 的人。每当有人需要用一个语言,就得去麻烦它的作者,那么这个语言的存在还有什么意义?

当然,很多 DSL 还会犯下程序语言设计的一些常见问题。很多人把设计语言想得太容易,喜欢耍新花样,到后来就因此出现各种麻烦事。容易出错,产生歧义,语法丑陋繁琐,难学难用,缺乏编辑器 IDE 支持,出错信息难以理解,无法用 debugger 调试,等等。最后你发现还不如不要设计新的语言,使用已有的语言来解决问题就可以

最强大的 DSL 实现语言

有些人很崇拜 Haskell 或者 Scala,说这两个语言有着非常强大的"DSL 实现能力",也就是说你可以用它们来实现自己想要的 DSL。这是一种误解。虽然我已经指出创造 DSL 并不是什么好事,我觉得还是应该把这个问题说清楚。如果你跟我一样看透了各种语言,就会发现世界上最强大的 DSL 实现语言,并不是 Haskell 或者 Scala,而是 Scheme。

2012 年的时候,我参加了 POPL 会议(Principles of Programming Languages),这是程序语言界的顶级会议。虽然名字里面含有 principle(原理)这个词,明眼人都看得出来,这个会议已经不是那么重视根本性的"原理",它已经带有随波逐流的商业气息。那时候 Scala 正如日中天,所以在那次会议上,Scala 的 paper 简直是铺天盖地,"Scala 帮"的人趾高气昂。当然,各种 JavaScript 的东西也是如火如荼。

很多 Scala 人宣讲的主题,都是在鼓吹它的 DSL 实现能力。听了几个这样的报告之后,我发现 Scala 的 DSL 机制跟 Haskell 的挺像,它们不过是实现了类似 C++ 的"操作符重载",利用特殊的操作符来表达对一些特殊对象的操作,然后把这些操作符美其名曰为"DSL"。

如果你还没看明白 Haskell 的把戏,我就提醒你一下。Haskell 的所谓 type class,其实跟 Java 或者 C++ 的函数重载(overloading)本质上是一回事。只不过因为 Haskell 采用了 Hindley-Milner 类型系统,这个重载问题被复杂化,模糊化了,所以一般人看不出来。等你看透了就会发现,Haskell 实现 DSL 的方式,不过是通过 type class 重载一些特殊的操作符而已。这跟 C++ 的 operator+(...) 并没有什么本质区别。

操作符重载定义出来的 DSL,是非常有局限性的。实际上,通过重载操作符定义出来的语言,并不能叫做 DSL,而只能叫做"库代码"。为什么呢?因为一个语言之所以成为"语言",它必须有自己独特的语义,而不只是定义了新的函数。重载操作符本质上只是定义了新的函数,而没有扩展语言的能力。就像你在 C++ 里重载了 + 操作符,你仍然是在使用 C++,而不是扩展了 C++ 的语义。

我用过 Haskell 实现的一个用于 GPU 计算的"DSL",名叫 Accelerate。这个"语言"用起来相当的蹩脚,它要求用户在代码的特定位置写上一些特殊符号,因为只有这样操作符重载才能起作用。可是写上这些莫名其妙的符号之后,你就发现代码的可读性变得很差。但由于操作符重载的局限性,你必须这样做。你必须记住在什么时候必须写这些符号,在什么时候不能写它们。这种要求对于程序员的头脑,是一个严重的负担,没有人愿意去记住这些不知所以的东西。

由于操作符重载的局限性,Haskell 和 Scala 实现的 DSL,虽然吹得很厉害,发了不少 paper,却很少有人拿来实用。

世界上最强大的 DSL 实现语言,其实非 Scheme 莫属。Scheme 的宏系统(hygienic macro)超越了早期 Lisp 语言的宏系统,它本来就是被设计来改变和扩展 Scheme 的语义的。Scheme 的宏实质上是在对"语法树"进行任意变换,扩展编译器的功能,所以你可以利用宏把 Scheme 转变成几乎任何你想要的语言。这种宏系统不但可以实现 Haskell 和 Scala 的"重载型 DSL",还能实现那些不能用重载实现的语言特性(比如能绑定变量的语句)。

miniKanren 就是一个用 Scheme 宏实现的语言,它是一个类似 Prolog 的逻辑式语言。如果你用 Haskell 或者 Scala 来实现 miniKanren,就会发现异常的困难。就算实现出来了,你的 DSL 语法也会很难看难用,不可能跟 miniKanren 一样优雅。

我并不是在这里鼓吹 Scheme,搞宣传。正好相反,对 Scheme 的宏系统有了深入理解之后,我发现了它带来的严重问题。内行人把这个问题称为"新语言问题"(The New Language Problem)。

因为在 Scheme 里实现一个新语言如此的容易,几行代码就可以写出新的语言构造,改变语言本来的语义,所以这带来了严重的问题。这个问题就是,一旦你改变了语言的语义,或者设计出新的语言构造,人们之间的交流就增加了一道障碍。使用你改造后的 Scheme 的人,必须学习一种新的语言,才能看懂你的代码,才能跟你交流。

由于这个原因,你很难看懂另一个人的 Scheme 代码,因为很多 Scheme 程序员觉得宏是个好东西,所以很喜欢用它。他们设计出稀奇古怪的宏,扩展语言的能力,然后使用扩展后的,你完全不理解的语言来写他的代码。本来语言是用来方便人与人交流的,结果由于每个人都可以改变这语言,导致他们鸡同鸭讲,没法交流!

再次声明,我不是在这里称赞或者宣扬 Scheme,我真的认为宏系统的存在是 Scheme 的一个严重的缺点。我那热爱 Scheme 的教授们知道了,一定会反对我这种说法,甚至鄙视我。但我确实就是这么想的,这么多年过去了,仍然没有改变过这一看法。

Scheme 宏系统的这个问题,引发了我对 DSL 的思考。后来我发现所谓 DSL 跟 Scheme 宏系统,存在几乎一模一样的问题。这个问题有一个名字,叫做"新语言问题"(The New Language Problem)。下面我详细解释一下这个问题。

NaCl 的故事

现在我来讲一个有趣的故事,是我自己跟 DSL 有关的经历。

在我曾经工作过的某公司,有两个很喜欢捣鼓 PL,却没有受过正规 PL 教育的人。说得不好听一点,他们就 是"PL 民科"。然而正是这种民科,最喜欢显示自己牛逼,喜欢显示自己有能力实现新的语言,以至于真正的专家 只好在旁边静静地看着他们装逼:P

他们其中一个人知道我是研究 PL 的,开头觉得我是同类,所以总喜欢走到桌前对我说:"咱们一起设计一个通用程序语言吧!然后用它来解决我们公司现在遇到的难题!"每当他这样说,我都安静的摇摇头:"我们公司真的需 要一个新的语言吗?你有多少时间来设计和实现这个语言?"

当时这两个人在公司里,总是喜欢试用各种新语言,Go 语言,Scala,Rust,…… 他们都试过了。每当拿到一个 新的项目,他们总是想方设法要用某种新语言来做。于是乎,这样的历史就在我眼前反复的上演:

- 1. 为一种新语言兴奋,开始用它来做新项目
- 两个月之后,开始骂这语言,各种不爽
 最后项目不了了之,代码全部丢进垃圾堆
- 4. Goto 1

这两个家伙每天就为这些事情忙得不亦乐乎,真正留下来的产出却很少。之前他们还设计了一种 DSL,专门用于 对 HTML 进行匹配和转换。这个 DSL 被他们起了一个很有科学味道的名字,叫做 NaCl(氯化钠,食盐的化学分 子式)。

我进公司的时候, NaCl 已经存在了挺长一段时间, 然而很少有人真正理解它的用法, 大部分人对它的态度都 是"能不碰就不碰"。终于有一天,我遇到了需要修改 NaCl 代码的时候。也就一行代码,看了半天 NaCl 的"官方文 档",却不知道如何才能用它提供的语法,来表达我所需要的改动。其实我需要的不过是一个很容易的匹配替换, 完全可以用正则表达式来完成,可是已有的代码是用 NaCl 写的,再加上好几层的框架,让你绕都绕不过,所以我 不知道怎么办了。

问了挺多人,包括公司里最顶级的"NaCl 专家",都没能得到结果。最后,我不得不硬着头皮去打扰两位日理万机 的"NaCl 之父"。叽里呱啦跟我解释说教了一通之后,眨眼之间噼里啪啦帮我改了代码,搞定了! 其实我根本没听 明白他在说什么,为什么那样改,也不知道背后的原理。总之,我一个字都没打,目的就达到了,所以我就回去 做自己的事情了。

后来跟其他同事聊,发现我的直觉是很准的。他们告诉我,公司里所有 NaCl 代码可以表达的东西,都可以很容易 的用正则表达式替换来解决,甚至可以用硬邦邦的,不带 regexp 的字符串替换来解决。同事们都很不理解,为什 么非得设计个 DSL 来做这么简单的事情,本来调用 Java 的 String.replace 就可以完成。

后来"NaCl 专家"告诉我,虽然他很了解 NaCl,却根本不喜欢它。在那两个家伙提出要设计 NaCl 的时候,他就已 经表示了强烈的反对,他觉得不应该创造 DSL 来解决这样的问题。当时他就给大家解释了什么是"新语言问题", 警告大家新语言会带来的麻烦。可是领导显然跟这两个家伙有某种政治上的联盟关系,所以根本没听他在说什

在领导的放任和支持下,这两个家伙一意孤行创造了 NaCl, 然后强行在全公司推广。到后来, 每次需要用 NaCl 写点什么,就发现需要给它增加新的功能,就得去求那两个家伙帮忙。所以我能用上今天的 NaCl,基本能表达我 想要的东西,还多亏了这位"NaCl 专家"以前栽的跟头,他把各种坑基本给我填起来了;)

我有一句格言:如果一个语言,每当用户需要用它表达任何东西,都得去麻烦它的设计者,甚至需要给这个语言 增加新的功能,那这个语言就不应该存在。NaCl 这个 DSL 正好符合了我的断言。

当然 NaCl 只是一个例子,我知道很多其它 DSL 的背后都有类似的故事。几个月之后,这两个民科又开始创造另 一个 DSL, 名叫 Dex, 于是历史又开始重演......

动态逻辑加载

Dex 的故事跟 NaCl 有所不同,但最后的结果差不多。NaCl 是一个完全不应该存在的语言,而 Dex 的情况有点不 一样。我们确实需要某种"嵌入式语言",只不过它不应该是 Dex 那个样子,不应该是一个 DSL。由于 Dex 要解决 的需求有一定的代表性,很多人在遇到这类需求的时候,就开始盲目的创造 DSL,所以这是一个很大的坑!我想 把这个故事详细讲一下,免得越来越多的人掉进去。

原来的需求是这样:产品需要一种配置方式,配置文件里面可以包含一定的"逻辑"。通过在不更换代码的情况下 动态加载配置文件,它可以动态的改变系统的逻辑和行为。这东西有点像"防火墙"的规则,比如:

- 1. 如果尺寸大于1000,那么不通过,否则通过。
- 2. 如果标题含有"猪头"这个词,不通过,否则通过......

这些规则从本质上讲,就是一些逻辑表达式"size > 1000",加上一些分支语句"if ... then ..."。在 Dex 出现之前,有 人用 XML 定义这样的规则,后来发现 XML 非常不好理解,像是这个样子:

<condition>

看明白了吗?这个看得人眼睛发涨的 XML,表达的不过是普通语言里面的 if (size > 1000) block()。为了理解这一点,你可以把这个 XML 所表示的"数据结构",想象成编译器里面的"抽象语法树"(AST)。所以写这个 XML,其实是在用手写 AST,那当然是相当痛苦的。

那我们为什么不把 if (size > 1000) block() 这条语句直接写到系统的 Java 代码里面呢? 因为 Java 代码是编译之后放进系统里面的,一旦放进去就不能随时换掉了。然而我们需要可以随时的,"动态"的替换掉这块逻辑,而不更新系统代码。所以你不能把这条 Java 语句"写死"到系统代码里面,而必须作为"配置"。

想清楚了这一点,你就自然找到了解决方案:把 if (x > 1000) block()这样的 Java 代码片段写到一个"配置文件"里,然后使用 JVM 读取,组合,并且编译这个文件,动态加载生成的 class,这样系统的行为就可以改变了。实际上这也就是公司里另外一个团队做过的事情,让用户编辑一个基于 Java 的"规则文件",然后加载它。

我觉得这不失为一个可行的解决方案。为了实现动态逻辑加载,你完全可以用像 Java 或者 JavaScript 那样已有的语言,利用已有的编译器来达到这个目的,而不需要设计新的语言。然而当 PL 民科们遇到这样的问题,他们首先想到的是:设计一个新的 DSL!于是 Dex 就诞生了。

Dex 要表达的东西,本质上就是这些逻辑表达式和条件语句,然而 Dex 被设计为一个完全独立的语言。它的语法被设计得其它语言很不一样,结合了 Haskell,Go 语言,Python 等各种语言语法的缺陷。后来团队里又进来一个研究过 Prolog 逻辑式语言的人,所以他试图在里面加入"逻辑式编程"的元素。总之他们有很宏伟的目标:让这个DSL "可靠","可验证",成为"描述式语言"……

他们向团队宣布这个雄心勃勃的计划之后,一个有趣的插曲发生了。听说又要创造一个 DSL, "NaCl 专家"再次怒发冲冠,开始反对这个计划。这一次他拿出了实际行动,自己动手拿 Java 内嵌的 <u>JavaScript 解释器</u>,做了一个基于 JavaScript 的动态配置系统,只开发了一个星期就可以用了。

我觉得用 JavaScript 也不失为一个解决方案,毕竟浏览器的 PAC 文件就是用 JavaScript 定义代理规则的,而这种代理规则跟我们的应用非常类似。我虽然没有特别喜欢 JavaScript,但它其中的一些简单构造用在这种场景,是没什么大问题的。

其实在此之前我也看不下去了,所以自己悄悄做了一个类似的配置系统,拿已有的 JavaScript parser,提取 JavaScript 的相关构造,做了一个解释器,嵌入到系统里,只花了一天时间。但我心里很清楚,一切技术上的努力 在政治斗争的面前,都是无足轻重的。我早已经伤不起了,在好心人的帮助下,我离开了这个团队,但暗地里我仍然从精神上支持着"NaCl 专家"继续他的抗争。

争吵的最后结果,当然是由于领导偏心庇护,否决了"外人"的作法,让两个民科和一个 Prolog 狂人继续开发 Dex。几个月之后,公司的第二个奇葩 DSL 诞生了。它用混淆难读的方式,表达了普通语言里的条件语句和逻辑 表达式。他们为它写了 parser,写了解释器,写了文档,开始在公司强行推广。"可靠","可验证","描述式"的目标,早已被抛到九霄云外。用的人都苦不堪言,好多东西没法表达或者不知道如何表达,出错了也没有足够的反馈信息,每次要写东西就得去找"Dex 之父"们。

嗯, 历史就这样重演了......

结论

所以,我对于 DSL 的结论是什么呢?

- 1. 尽一切可能避免创造 DSL,因为它会带来严重的理解,交流和学习曲线问题,可能会严重的降低团队的工作效率。如果这个 DSL 是给用户使用,会严重影响用户体验,降低产品的可用性。
- 2. 大部分时候写库代码,把需要的功能做成函数,其实就可以解决问题。
- 3. 如果真的到了必须创造 DSL 的时候,非 DSL 不能解决问题,才可以动手设计 DSL。但 DSL 必须由程序语言专家来完成,否则它还是可能给产品和团队带来严重的后果。
- 4. 大部分 DSL 要解决的问题,不过是"动态逻辑加载"。为了这个目的,你完全可以利用已有的语言(比如 JavaScript),或者取其中一部分构造,通过动态调用它的解释器(编译器)来达到这个目的,而不需要创造新的 DSL。

(本文建议零售价 ¥30,如果它让你的团队或者公司幸免落坑,请付款 ¥1000000:)