DSL 的误区

DSL 时不时地会成为一个话题, 所以今天想专门说一下。

DSL 也就是 Domain Specific Language 的简称,是指为特定领域(domain)设计的专用语言。举个例子,Linux 系统下有很多配置文件,每个配置文件格式都不大一样,它们可以被看成是多种 DSL。IP Tables 的规则是一种 DSL,FVWM 窗口管理器的配置文件是一种 DSL,VIM 和 Emacs 的配置文件,当然也是 DSL。Makefile 是 DSL。CSS 是 DSL。JSON 是 DSL。SQL 也可以被看成是数据库领域的 DSL。也有很多人在自己的工作中创造 DSL,用它们来解决一些实际问题。

由于自己的原则,我个人从来没有设计过 DSL,但我用过别人设计的 DSL,并且对此深有感受。我觉得人们对于 DSL 有挺多的误解,所以我今天想分享一下自己对 DSL 的看法和亲身经历。

DSL 与库代码(Library)

开门见山说说对 DSL 的看法吧。我觉得大部分 DSL 都是不应该存在的,我们应该尽量避免创造 DSL。这一论点不但适用于只有少量用户的产品内部 DSL,也适用于像 SQL 这样具有大量从业者的 DSL。

DSL 这名字本身就是一种误导,它让人误以为不同"领域"(domain)的人就该用不同的语言,而其实不是那样的。这不过是在制造领域壁垒,为引入不必要的 DSL 找借口。绝大部分所谓不同"领域",它们对语言的基本需求都是一样的。很多时候人们误以为需要新的 DSL,是因为他们没有分清"库代码"(library)和"新语言"(language)的差别。

不同领域需要的,绝大部分时候只是针对该领域写出的"库代码",而不是完全不同的"新语言"。分析大部分所谓 DSL,你会发现它们不过提取了通用程序语言里的一部分,比如结构定义,算术表达式,逻辑表达式,条件语句,等等。极少有 DSL 是不能用通用的程序语言构造表示的。绝大部分时候你都可以用一种通用的语言,写出满足领域需求的库代码,然后领域里的人就可以调用库函数来完成他们的任务。

绝大部分 DSL 的存在,都是因为设计它的人没有理解问题的本质,没有意识到这问题并不需要通过设计新的语言来解决。 很多人设计 DSL,是因为看到同类产品里面有 DSL,所以就抄袭照搬。或者因为听说 DSL 很酷,设计出 DSL 会显得自己很厉害,很有价值。同时,设计 DSL 还可以让同事和公司对自己产生依赖性。因为有人用我的 DSL,所以公司需要我,离不开我,那么 job security 就有所保证;)

然而如果你仔细分析手头的问题,就会发现它们绝大部分都可以用库代码,利用已有的语言来解决。就算类似的产品里面实现了 DSL,你会发现它们绝大部分也可以用库代码来代替。在自己的工作中,我一般都首先考虑写库代码来解决问题,实在解决不了才会考虑创造 DSL。

因为遵循这一原则,加上对问题透彻的理解,我发现自己几乎每次都能用库代码解决问题,所以我从来没有在自己的职业生涯中创造过 DSL。

"新语言问题" (The New Language Problem)

现在我来讲一下,盲目创造 DSL 带来的问题。很多人不明白 DSL 跟库代码的区别,拿到一个问题也不想清楚,就一意孤行 开始设计 DSL,后来却发现 DSL 带来了严重的问题。由于 DSL 是一种新的语言,而不只是用已有语言写出来新函数,所以 DSL 必须经过一个学习和理解的过程,才能被其他人使用。

举个例子。如果你看到 foo(x, y + z) 这样的库代码,很显然这是一个函数调用,所以你知道它会先计算 y+z,得到结果之后,把它传递给 foo 函数作为参数,最后得到 foo 函数算出来的结果。注意到了吗,你并不需要学习新的语言。虽然你不知道 foo 函数的定义,然而你很清楚函数调用会做什么:把参数算好放进去,返回一个结果。也就是说,你对函数调用已经有一个"心理模型"。

可是一个 DSL 就很不一样,对于一个新的 DSL 构造,你也许没有任何心理模型存在。同样看到 foo(x, y + z),它的含义也许根本不是一个函数调用。也许 foo 在这个 DSL 里就表示 foreach 循环语句,那么 foo(x, y + z) 表示类似 Java 的 foreach(x : y + z),其中 y 和 z 都是链表, y 号表示连接两个链表。

这样一来,为了理解 foo(x, y + z) 是什么意义,你不能直接通过已有的,关于函数的心理模型,而必须阅读 DSL 设计者给你的文档,重新学习。如果 DSL 设计者是有素养的语言专家,那也许还好说。然而我发现绝大部分 DSL 设计者,都没有受到过专业的训练,所以他们设计出来的语言,从一开始就存在各种让人头痛的问题。

有些 DSL 表达力太弱,所以很多时候用户发现没法表达自己的意思。每当需要用这 DSL 写代码,他们就得去请教这个语言的设计者。很多时候你必须往这个 DSL 添加新的特性,才能解决自己的问题。到后来,你就发现有人设计了个 DSL,到头来他自己是唯一会用这 DSL 的人。每当有人需要用一个语言,就得去麻烦它的作者,那么这个语言的存在还有什么意义?

当然,很多 DSL 还会犯下程序语言设计的一些常见问题。很多人把设计语言想得太容易,喜欢耍新花样,到后来就因此出现各种麻烦事。容易出错,产生歧义,语法丑陋繁琐,难学难用,缺乏编辑器 IDE 支持,出错信息难以理解,无法用debugger 调试,等等。最后你发现还不如不要设计新的语言,使用已有的语言来解决问题就可以了。

最强大的 DSL 实现语言

有些人很崇拜 Haskell 或者 Scala,说这两个语言有着非常强大的"DSL 实现能力",也就是说你可以用它们来实现自己想要的 DSL。这是一种误解。虽然我已经指出创造 DSL 并不是什么好事,我觉得还是应该把这个问题说清楚。如果你跟我一样看透了各种语言,就会发现世界上最强大的 DSL 实现语言,并不是 Haskell 或者 Scala,而是 Scheme。

2012 年的时候,我参加了 POPL 会议(Principles of Programming Languages),这是程序语言界的顶级会议。虽然名字里面 含有 principle(原理)这个词,明眼人都看得出来,这个会议已经不是那么重视根本性的"原理",它已经带有随波逐流的商业气息。那时候 Scala 正如日中天,所以在那次会议上,Scala 的 paper 简直是铺天盖地,"Scala 帮"的人趾高气昂。当然,各

种 JavaScript 的东西也是如火如荼。

很多 Scala 人宣讲的主题,都是在鼓吹它的 DSL 实现能力。听了几个这样的报告之后,我发现 Scala 的 DSL 机制跟 Haskell 的挺像,它们不过是实现了类似 C++ 的"操作符重载",利用特殊的操作符来表达对一些特殊对象的操作,然后把这些操作符美其名曰为"DSL"。

如果你还没看明白 Haskell 的把戏,我就提醒你一下。Haskell 的所谓 type class,其实跟 Java 或者 C++ 的函数重载(overloading)本质上是一回事。只不过因为 Haskell 采用了 Hindley-Milner 类型系统,这个重载问题被复杂化,模糊化了,所以一般人看不出来。等你看透了就会发现,Haskell 实现 DSL 的方式,不过是通过 type class 重载一些特殊的操作符而已。这跟 C++ 的 operator+(...) 并没有什么本质区别。

操作符重载定义出来的 DSL,是非常有局限性的。实际上,通过重载操作符定义出来的语言,并不能叫做 DSL,而只能叫做"库代码"。为什么呢?因为一个语言之所以成为"语言",它必须有自己独特的语义,而不只是定义了新的函数。重载操作符本质上只是定义了新的函数,而没有扩展语言的能力。就像你在 C++ 里重载了 + 操作符,你仍然是在使用 C++,而不是扩展了 C++ 的语义。

我用过 Haskell 实现的一个用于 GPU 计算的"DSL",名叫 Accelerate。这个"语言"用起来相当的蹩脚,它要求用户在代码的特定位置写上一些特殊符号,因为只有这样操作符重载才能起作用。可是写上这些莫名其妙的符号之后,你就发现代码的可读性变得很差。但由于操作符重载的局限性,你必须这样做。你必须记住在什么时候必须写这些符号,在什么时候不能写它们。这种要求对于程序员的头脑,是一个严重的负担,没有人愿意去记住这些不知所以的东西。

由于操作符重载的局限性, Haskell 和 Scala 实现的 DSL, 虽然吹得很厉害, 发了不少 paper, 却很少有人拿来实用。

世界上最强大的 DSL 实现语言,其实非 Scheme 莫属。Scheme 的宏系统(hygienic macro)超越了早期 Lisp 语言的宏系统,它本来就是被设计来改变和扩展 Scheme 的语义的。Scheme 的宏实质上是在对"语法树"进行任意变换,扩展编译器的功能,所以你可以利用宏把 Scheme 转变成几乎任何你想要的语言。这种宏系统不但可以实现 Haskell 和 Scala 的"重载型 DSL",还能实现那些不能用重载实现的语言特性(比如能绑定变量的语句)。

miniKanren 就是一个用 Scheme 宏实现的语言,它是一个类似 Prolog 的逻辑式语言。如果你用 Haskell 或者 Scala 来实现 miniKanren,就会发现异常的困难。就算实现出来了,你的 DSL 语法也会很难看难用,不可能跟 miniKanren 一样优雅。

我并不是在这里鼓吹 Scheme,搞宣传。正好相反,对 Scheme 的宏系统有了深入理解之后,我发现了它带来的严重问题。内行人把这个问题称为"新语言问题"(The New Language Problem)。

因为在 Scheme 里实现一个新语言如此的容易,几行代码就可以写出新的语言构造,改变语言本来的语义,所以这带来了严重的问题。这个问题就是,一旦你改变了语言的语义,或者设计出新的语言构造,人们之间的交流就增加了一道障碍。使用你改造后的 Scheme 的人,必须学习一种新的语言,才能看懂你的代码,才能跟你交流。

由于这个原因,你很难看懂另一个人的 Scheme 代码,因为很多 Scheme 程序员觉得宏是个好东西,所以很喜欢用它。他们设计出稀奇古怪的宏,扩展语言的能力,然后使用扩展后的,你完全不理解的语言来写他的代码。本来语言是用来方便人与人交流的,结果由于每个人都可以改变这语言,导致他们鸡同鸭讲,没法交流!

再次声明,我不是在这里称赞或者宣扬 Scheme,我真的认为宏系统的存在是 Scheme 的一个严重的缺点。我那热爱 Scheme 的教授们知道了,一定会反对我这种说法,甚至鄙视我。但我确实就是这么想的,这么多年过去了,仍然没有改变过这一看法。

Scheme 宏系统的这个问题,引发了我对 DSL 的思考。后来我发现所谓 DSL 跟 Scheme 宏系统,存在几乎一模一样的问题。这个问题有一个名字,叫做"新语言问题"(The New Language Problem)。下面我详细解释一下这个问题。

NaCl 的故事

现在我来讲一个有趣的故事,是我自己跟 DSL 有关的经历。

在我曾经工作过的某公司,有两个很喜欢捣鼓 PL,却没有受过正规 PL 教育的人。说得不好听一点,他们就是"PL 民科"。 然而正是这种民科,最喜欢显示自己牛逼,喜欢显示自己有能力实现新的语言,以至于真正的专家只好在旁边静静地看着他 们装逼:P

他们其中一个人知道我是研究 PL 的,开头觉得我是同类,所以总喜欢走到桌前对我说:"咱们一起设计一个通用程序语言吧!然后用它来解决我们公司现在遇到的难题!"每当他这样说,我都安静的摇摇头:"我们公司真的需要一个新的语言吗?你有多少时间来设计和实现这个语言?"

当时这两个人在公司里,总是喜欢试用各种新语言,Go语言,Scala, Rust, …… 他们都试过了。每当拿到一个新的项目,他们总是想方设法要用某种新语言来做。于是乎,这样的历史就在我眼前反复的上演:

- 1. 为一种新语言兴奋,开始用它来做新项目
- 2. 两个月之后, 开始骂这语言, 各种不爽
- 3. 最后项目不了了之, 代码全部丢进垃圾堆
- 4. Goto 1

这两个家伙每天就为这些事情忙得不亦乐乎,真正留下来的产出却很少。之前他们还设计了一种 DSL,专门用于对 HTML 进行匹配和转换。这个 DSL 被他们起了一个很有科学味道的名字,叫做 NaCl(氯化钠,食盐的化学分子式)。

我进公司的时候,NaCl 已经存在了挺长一段时间,然而很少有人真正理解它的用法,大部分人对它的态度都是"能不碰就不碰"。终于有一天,我遇到了需要修改 NaCl 代码的时候。也就一行代码,看了半天 NaCl 的"官方文档",却不知道如何才能用它提供的语法,来表达我所需要的改动。其实我需要的不过是一个很容易的匹配替换,完全可以用正则表达式来完成,可

是已有的代码是用 NaCl 写的,再加上好几层的框架,让你绕都绕不过,所以我不知道怎么办了。

问了挺多人,包括公司里最顶级的"NaCl专家",都没能得到结果。最后,我不得不硬着头皮去打扰两位日理万机的"NaCl之父"。叽里呱啦跟我解释说教了一通之后,眨眼之间噼里啪啦帮我改了代码,搞定了!其实我根本没听明白他在说什么,为什么那样改,也不知道背后的原理。总之,我一个字都没打,目的就达到了,所以我就回去做自己的事情了。

后来跟其他同事聊,发现我的直觉是很准的。他们告诉我,公司里所有 NaCl 代码可以表达的东西,都可以很容易的用正则表达式替换来解决,甚至可以用硬邦邦的,不带 regexp 的字符串替换来解决。同事们都很不理解,为什么非得设计个 DSL 来做这么简单的事情,本来调用 Java 的 String.replace 就可以完成。

后来"NaCl 专家"告诉我,虽然他很了解 NaCl, 却根本不喜欢它。在那两个家伙提出要设计 NaCl 的时候,他就已经表示了强烈的反对,他觉得不应该创造 DSL 来解决这样的问题。当时他就给大家解释了什么是"新语言问题",警告大家新语言会带来的麻烦。可是领导显然跟这两个家伙有某种政治上的联盟关系,所以根本没听他在说什么。

在领导的放任和支持下,这两个家伙一意孤行创造了 NaCl, 然后强行在全公司推广。到后来,每次需要用 NaCl 写点什么,就发现需要给它增加新的功能,就得去求那两个家伙帮忙。所以我能用上今天的 NaCl, 基本能表达我想要的东西,还多亏了这位"NaCl 专家"以前栽的跟头,他把各种坑基本给我填起来了;)

我有一句格言:如果一个语言,每当用户需要用它表达任何东西,都得去麻烦它的设计者,甚至需要给这个语言增加新的功能,那这个语言就不应该存在。NaCl 这个 DSL 正好符合了我的断言。

当然 NaCl 只是一个例子,我知道很多其它 DSL 的背后都有类似的故事。几个月之后,这两个民科又开始创造另一个 DSL, 名叫 Dex, 于是历史又开始重演……

动态逻辑加载

Dex 的故事跟 NaCl 有所不同,但最后的结果差不多。NaCl 是一个完全不应该存在的语言,而 Dex 的情况有点不一样。我们确实需要某种"嵌入式语言",只不过它不应该是 Dex 那个样子,不应该是一个 DSL。由于 Dex 要解决的需求有一定的代表性,很多人在遇到这类需求的时候,就开始盲目的创造 DSL,所以这是一个很大的坑!我想把这个故事详细讲一下,免得越来越多的人掉进去。

原来的需求是这样:产品需要一种配置方式,配置文件里面可以包含一定的"逻辑"。通过在不更换代码的情况下动态加载配置文件,它可以动态的改变系统的逻辑和行为。这东西有点像"防火墙"的规则,比如:

- 1. 如果尺寸大于1000,那么不通过,否则通过。
- 2. 如果标题含有"猪头"这个词,不通过,否则通过......

这些规则从本质上讲,就是一些逻辑表达式"size > 1000",加上一些分支语句"if ... then ..."。在 Dex 出现之前,有人用 XML 定义这样的规则,后来发现 XML 非常不好理解,像是这个样子:

<rule>

<condition>
 <operator>gt</operator>
 <first>size</first>
 <second>1000</second>
</condition>

<action>block</action>

</rule>

看明白了吗?这个看得人眼睛发涨的 XML,表达的不过是普通语言里面的 if (size > 1000) block()。为了理解这一点,你可以把这个 XML 所表示的"数据结构",想象成编译器里面的"抽象语法树"(AST)。所以写这个 XML,其实是在用手写 AST,那当然是相当痛苦的。

那我们为什么不把 if (size > 1000) block()这条语句直接写到系统的 Java 代码里面呢?因为 Java 代码是编译之后放进系统里面的,一旦放进去就不能随时换掉了。然而我们需要可以随时的,"动态"的替换掉这块逻辑,而不更新系统代码。所以你不能把这条 Java 语句"写死"到系统代码里面,而必须作为"配置"。

想清楚了这一点,你就自然找到了解决方案:把 if (x > 1000) block()这样的 Java 代码片段写到一个"配置文件"里,然后使用 JVM 读取,组合,并且编译这个文件,动态加载生成的 class,这样系统的行为就可以改变了。实际上这也就是公司里另外一个团队做过的事情,让用户编辑一个基于 Java 的"规则文件",然后加载它。

我觉得这不失为一个可行的解决方案。为了实现动态逻辑加载,你完全可以用像 Java 或者 JavaScript 那样已有的语言,利用已有的编译器来达到这个目的,而不需要设计新的语言。然而当 PL 民科们遇到这样的问题,他们首先想到的是:设计一个新的 DSL!于是 Dex 就诞生了。

Dex 要表达的东西,本质上就是这些逻辑表达式和条件语句,然而 Dex 被设计为一个完全独立的语言。它的语法被设计得其它语言很不一样,结合了 Haskell,Go 语言,Python 等各种语言语法的缺陷。后来团队里又进来一个研究过 Prolog 逻辑式语言的人,所以他试图在里面加入"逻辑式编程"的元素。总之他们有很宏伟的目标:让这个 DSL "可靠","可验证",成为"描述式语言"……

他们向团队宣布这个雄心勃勃的计划之后,一个有趣的插曲发生了。听说又要创造一个 DSL,"NaCl 专家"再次怒发冲冠, 开始反对这个计划。这一次他拿出了实际行动,自己动手拿 Java 内嵌的 <u>JavaScript 解释器</u>,做了一个基于 JavaScript 的动态 配置系统,只开发了一个星期就可以用了。

我觉得用 JavaScript 也不失为一个解决方案,毕竟浏览器的 PAC 文件就是用 JavaScript 定义代理规则的,而这种代理规则跟

我们的应用非常类似。我虽然没有特别喜欢 JavaScript, 但它其中的一些简单构造用在这种场景, 是没什么大问题的。

其实在此之前我也看不下去了,所以自己悄悄做了一个类似的配置系统,拿已有的 JavaScript parser,提取 JavaScript 的相关构造,做了一个解释器,嵌入到系统里,只花了一天时间。但我心里很清楚,一切技术上的努力在政治斗争的面前,都是无足轻重的。我早已经伤不起了,在好心人的帮助下,我离开了这个团队,但暗地里我仍然从精神上支持着"NaCl 专家"继续他的抗争。

争吵的最后结果,当然是由于领导偏心庇护,否决了"外人"的作法,让两个民科和一个 Prolog 狂人继续开发 Dex。几个月之后,公司的第二个奇葩 DSL 诞生了。它用混淆难读的方式,表达了普通语言里的条件语句和逻辑表达式。他们为它写了parser,写了解释器,写了文档,开始在公司强行推广。"可靠","可验证","描述式"的目标,早已被抛到九霄云外。用的人都苦不堪言,好多东西没法表达或者不知道如何表达,出错了也没有足够的反馈信息,每次要写东西就得去找"Dex 之父"们。

嗯,历史就这样重演了......

结论

所以,我对于 DSL 的结论是什么呢?

- 1. 尽一切可能避免创造 DSL,因为它会带来严重的理解,交流和学习曲线问题,可能会严重的降低团队的工作效率。如果 这个 DSL 是给用户使用,会严重影响用户体验,降低产品的可用性。
- 2. 大部分时候写库代码,把需要的功能做成函数,其实就可以解决问题。
- 3. 如果真的到了必须创造 DSL 的时候,非 DSL 不能解决问题,才可以动手设计 DSL。但 DSL 必须由程序语言专家来完成,否则它还是可能给产品和团队带来严重的后果。
- 4. 大部分 DSL 要解决的问题,不过是"动态逻辑加载"。为了这个目的,你完全可以利用已有的语言(比如 JavaScript),或者取其中一部分构造,通过动态调用它的解释器(编译器)来达到这个目的,而不需要创造新的 DSL。

(本文建议零售价 ¥30, 如果它让你的团队或者公司幸免落坑, 请付款 ¥1000000:)